Анализ тональности русскоязычных отзывов о товарах: ансамбль дообученных трансформеров на RuReviews

Баженов Данил Борисович

Октябрь 2026

Аннотация

Мы рассматриваем задачу трёхклассовой классификации тональности (негативная / нейтральная / позитивная) русскоязычных отзывов о товарах на открытом датасете RuReviews [Smetanin and Komarov, 2019]. Мы анализируем датасет и показываем, что в стандартном протоколе оценки около 6% тестовых отзывов дословно (после нормализации) встречаются в обучающей выборке, а 388 текстов имеют противоречивые метки; поэтому дополнительно предлагается протокол без пересечений. Мы сравниваем TF-IDF-бейзлайн, воспроизведение опубликованных подходов (RuBERT, XLM-RoBERTa-Large) и современные энкодеры (RuModernBERT, ruRoBERTa-large), а также предлагаем ансамбль с весами, подобранными на валидации. Ансамбль достигает macro-F1 = 80.14% на тесте, что выше лучшего опубликованного результата 78.81% [Smetanin, 2022a]. Код: `https://github.com/danil39russia/rureviews-sentiment`.

1 Введение

Анализ тональности отзывов — одна из наиболее востребованных прикладных задач NLP: маркетплейсы используют его для мониторинга качества товаров и продавцов, ранжирования отзывов и выявления проблемных позиций. Для русского языка качество моделей заметно отстаёт от английского из-за меньшего числа размеченных корпусов [Kotelnikov, 2021].

Особенно сложен класс «нейтральный»: он лежит между двумя полюсами и в отзывах часто выражается смешанными оценками («ткань хорошая, но размер маломерит»). Именно на нём ошибаются все модели в работе [Smetanin and Komarov, 2021].

Наш вклад:

- анализ качества датасета RuReviews: дубликаты, противоречивые метки и утечка между train и test в стандартном протоколе, а также альтернативный протокол без пересечений;
- единый воспроизводимый пайплайн сравнения: TF-IDF, RuBERT, XLM-R-Large, RuModernBERT, ruRoBERTa-large на одном и том же разбиении;
- ансамбль с весами, обученными на валидации, который превосходит лучший опубликованный результат на RuReviews.

1.1 Команда

Баженов Данил Борисович — подготовка данных, реализация и проведение всех экспериментов, написание отчёта.

2 Обзор литературы

Датасеты. Обзор русскоязычных корпусов тональности приведён в [Kotelnikov, 2021]. Основные открытые наборы: SentiRuEval-2016 (твиты о банках и телекоммпаниях) [Loukachevitch and Rubtsova, 2016], RuSentiment (посты ВКонтакте) [Rogers et al., 2018],

RuSentiTweet [Smetanin, 2022b], а также RuReviews [Smetanin and Komarov, 2019] — отзывы о товарах категории «Женская одежда и аксессуары».

Подходы до трансформеров. Авторы RuReviews использовали свёрточную сеть [Kim, 2014] поверх эмбеддингов Word2Vec, обученных на отзывах, с препроцессингом (нижний регистр, теги для удлинённых и капслок-слов, замена эмотиконов). Результат — macro-F1 = 75.45%.

Дообучение трансформеров. В [Smetanin and Komarov, 2021] дообучены Multilingual BERT [Devlin et al., 2019], RuBERT [Kuratov and Arkhipov, 2019] и две версии Multilingual USE на семи русскоязычных датасетах. Для датасетов без готового разбиения использовался случайный сплит 70/15/15. На RuReviews лучший результат показал RuBERT: macro-F1 = 77.44%. В продолжении этой работы [Smetanin, 2022a] сравнены 12 предобученных трансформеров; лучший на RuReviews — XLM-RoBERTa-Large [Conneau et al., 2020] с F1 = 78.81%, далее LaBSE (78.47) и XLM-R-Base (78.28). Этот результат мы считаем текущим SotA. В [Golubev and Loukachevitch, 2021] показано, что дополнительный трансфер с автоматически размеченных данных улучшает результаты на RuSentiment и SentiRuEval.

Новые модели для русского языка. После 2022 года появились ruRoBERTa-large [Zmitrovich et al., 2023], RuModernBERT (адаптация ModernBERT [Warner et al., 2024]) и многоязычные эмбеддеры E5 [Wang et al., 2024]. В бенчмарке ruMTEB [Snegirev et al., 2025] есть задача RuReviewsClassification, но там модели оцениваются как замороженные эмбеддеры с логистической регрессией, поэтому числа не сравнимы с дообучением.

LLM. Большие языковые модели в zero-shot режиме уступают дообученным моделям на задачах тональности с тонкими границами классов [Zhang et al., 2024]; альтернативой является дообучение LLM с классификационной головой через LoRA/QLoRA [Hu et al., 2022, Dettmers et al., 2023, Li et al., 2023].

3 Описание модели

Каждая модель-участник m — трансформер-энкодер с линейным классификатором поверх представления первого токена, дообученный целиком с кросс-энтропией. На выходе модель даёт логиты $z^{(m)}(x) \in \mathbb{R}^3$.

Ансамбль. Итоговое распределение — взвешенное среднее логарифмов вероятностей участников:

$$\log p(y \mid x) \propto \sum_{m=1}^{M} w_m \log \operatorname{softmax}\big(z^{(m)}(x)\big)_y, \qquad w_m \geq 0,\ \sum_m w_m = 1.$$

Веса w подбираются минимизацией log-loss на *валидационной* выборке (метод Нелдера–Мида, параметризация через softmax). Тестовая выборка используется один раз для финальной оценки. Предсказание — $\arg\max_y p(y \mid x)$.

Мотивация: модели с разными токенизаторами и корпусами предобучения (многоязычный XLM-R, русскоязычные ruRoBERTa и RuBERT, RuModernBERT с современной архитектурой, а также символьные n-граммы TF-IDF) ошибаются по-разному, и усреднение снижает дисперсию [Dietterich, 2000]. Это особенно важно для шумных автоматических меток RuReviews.

Участники ансамбля:

- **XLM-RoBERTa-Large** (560M параметров) — воспроизведение текущего SotA;
- **ruRoBERTa-large** (355M) — RoBERTa, предобученная на русскоязычных текстах [Zmitrovich et al., 2023];
- **RuModernBERT-base** (150M) — ModernBERT для русского языка;
- **RuBERT-base** (180M) — воспроизведение [Smetanin and Komarov, 2021];
- **TF-IDF + логистическая регрессия** — словные (1–2) и символьные (2–5) n-граммы.

4 Датасет

RuReviews [Smetanin and Komarov, 2019] содержит отзывы о товарах категории «Женская одежда и аксессуары» с крупного российского маркетплейса. Метки получены автоматически из пользовательских оценок: 1–2 звезды — негатив, 3 — нейтрально, 4–5 — позитив. Исходные 821k отзывов сбалансированы андерсемплингом до 30 000 на класс. Датасет распространяется по лицензии Apache-2.0 и доступен по ссылке[1]; скрипт загрузки — `scripts/download_data.sh`.

Анализ качества данных. Мы обнаружили (Табл. 1): 2 679 точных дубликатов; 5 068 дубликатов после нормализации (нижний регистр, *ё*→*е*, удаление пунктуации); 388 текстов, встречающихся с *разными* метками, хотя авторы заявляют, что конфликты разрешены голосованием. Типичные примеры — короткие шаблонные отзывы: «Товар не пришёл» (58 раз, метки negative и neutral), «Товар не пришёл, деньги вернули» и даже отзыв из одной точки «.» (46 раз) встречаются со всеми тремя метками.

Всего отзывов	90 000
Точных дубликатов	2 679
Дубликатов после нормализации	5 068
Текстов с противоречивыми метками	388
Средняя длина, символов / слов	130.1 / 20.0
Медианная длина, символов	91

Таблица 1: Статистика и качество данных RuReviews.

Протоколы разбиения. Официального разбиения нет. Мы используем два протокола (Табл. 2):

1. **random** — стратифицированный случайный сплит 70/15/15, как в [Smetanin and Komarov, 2021]; используется для сравнения с опубликованными результатами. При этом 830 тестовых отзывов (6.1%) после нормализации встречаются в train, то есть часть теста модель фактически видела [Elangovan et al., 2021];
2. **dedup** — те же пропорции, но разбиваются уникальные нормализованные тексты, так что пересечений между частями нет.

	Train	Valid	Test	Тест ∩ Train
random	63 000	13 500	13 500	830
dedup	62 435	13 977	13 588	0

Таблица 2: Размеры частей для двух протоколов. Классы сбалансированы (по ≈1/3) во всех частях.

5 Эксперименты

5.1 Метрики

Основная метрика — macro-F1, как в [Smetanin and Komarov, 2019, Smetanin and Komarov, 2021]:

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \qquad \text{macro-F1} = \frac{1}{3}\sum_{c\in\{neg,neu,pos\}} F1_c,$$

где P_c и R_c — точность и полнота класса c. Дополнительно приводятся macro-precision, macro-recall, accuracy и F1 по классам.

[1] `https://github.com/sismetanin/rureviews`

5.2 Постановка эксперимента

Все модели обучаются на train, лучшая эпоха выбирается по macro-F1 на valid, результат приводится на test. Гиперпараметры: AdamW, линейный warmup 10%, weight decay 0.01, максимальная длина 256 токенов, эффективный батч 32, bf16. Base-модели: 3 эпохи, lr $3 \cdot 10^{-5}$ (RuBERT) и $5 \cdot 10^{-5}$ (RuModernBERT). Large-модели: 8-битный AdamW, батч 8×4; XLM-R-Large — 3 эпохи, lr 10^{-5}; ruRoBERTa-large — 1 эпоха, lr $2 \cdot 10^{-5}$. TF-IDF: до 300k словных и 300k символьных признаков, логистическая регрессия с $C = 4$. Seed 42 для сплита и обучения. Оборудование — одна NVIDIA RTX 5080 (16 ГБ).

5.3 Бейзлайны

- TF-IDF + логистическая регрессия — простой бейзлайн;
- CNN + Word2Vec [Smetanin and Komarov, 2019], RuBERT [Smetanin and Komarov, 2021], XLM-R-Large [Smetanin, 2022a] — опубликованные результаты. RuBERT и XLM-R-Large дополнительно воспроизведены на нашем разбиении, поскольку seed исходного сплита не опубликован.

6 Результаты

Сравнение с опубликованными работами приведено в Табл. 3, подробные метрики — в Табл. 4.

Модель	**Test macro-F1, %**
Опубликованные результаты (сплит 70/15/15, seed неизвестен)	
CNN + Word2Vec [Smetanin and Komarov, 2019]	75.45
RuBERT [Smetanin and Komarov, 2021]	77.44
XLM-RoBERTa-Large [Smetanin, 2022a]	78.81
Наши запуски (протокол random)	
TF-IDF + LogReg	75.07
RuBERT-base (воспр.)	78.28
RuModernBERT-base	78.57
XLM-RoBERTa-Large (воспр.)	79.44
ruRoBERTa-large	79.12
Ансамбль, равные веса (абляция)	79.89
Ансамбль, веса по валидации (наш)	**80.14**

Таблица 3: Сравнение с предыдущими работами на RuReviews.

Модель	P	R	Acc	$F1_{neg}$	$F1_{neu}$	$F1_{pos}$
TF-IDF + LogReg	75.17	74.99	74.99	72.18	65.15	87.87
RuBERT-base	78.90	78.00	78.00	75.00	69.92	89.92
RuModernBERT-base	79.41	78.27	78.27	74.68	70.67	90.37
ruRoBERTa-large	79.28	78.99	78.99	76.63	69.92	90.81
XLM-RoBERTa-Large	79.93	79.25	79.25	75.94	71.51	90.88
Ансамбль, равные веса	80.36	79.68	79.68	76.60	71.86	91.22
Ансамбль (наш)	**80.59**	**79.93**	**79.93**	**76.79**	**72.22**	**91.40**

Таблица 4: Подробные метрики на тесте (протокол random, %): macro-precision, macro-recall, accuracy и F1 по классам. Веса ансамбля, подобранные на валидации: ruRoBERTa-large 0.33, XLM-R-Large 0.32, RuModernBERT 0.19, TF-IDF 0.11, RuBERT 0.05.

Интерпретация.

- Простой TF-IDF-бейзлайн (75.07) почти достигает результата CNN из оригинальной работы (75.45): датасет во многом решается лексическими признаками.

- Воспроизведённый RuBERT на нашем сплите (78.28) немного выше опубликованного (77.44). Это согласуется с разбросом от выбора сплита и с утечкой дубликатов в протоколе random.
- Воспроизведённый XLM-R-Large (79.44) также выше опубликованного значения (78.81). Поэтому для честного сравнения ансамбль сопоставляется не только с опубликованными числами, но и с сильнейшей одиночной моделью на *том же* разбиении.
- Ансамбль превосходит и лучший опубликованный результат (78.81), и все одиночные модели на нашем разбиении, accuracy = 79.93%. Ансамбль с равными весами (79.89) хуже ансамбля с весами, подобранными на валидации: вклад участников неравноценен.
- Как и в [Smetanin and Komarov, 2021], основная доля ошибок связана с нейтральным классом: F1 для него (72.2 у ансамбля) заметно ниже, чем для негатива (76.8) и позитива (91.4). Ансамбль улучшает F1 по всем трём классам. Часть ошибок объясняется шумом меток (Табл. 1): одинаковые тексты встречаются с разными оценками, что задаёт потолок качества для любой модели.

Ограничения. Все результаты получены с одним seed; из-за ограничений по времени не проведены запуски с несколькими seed, оценка на протоколе dedup, а также эксперименты с LLM (Qwen2.5-7B: zero-/few-shot и QLoRA-классификатор). Код для них есть в репозитории (`src/zero_shot_llm.py`, `src/train_llm_lora.py`).

7 Заключение

Мы проанализировали датасет RuReviews и нашли в нём дубликаты, противоречивые метки и утечку между train и test в стандартном протоколе оценки; предложен протокол без пересечений. В едином воспроизводимом пайплайне сравнены TF-IDF, RuBERT, XLM-R-Large, RuModernBERT и ruRoBERTa-large. Предложенный ансамбль с весами, подобранными на валидации, достигает macro-F1 = 80.14% и превосходит лучший опубликованный результат на RuReviews (78.81%). Дальнейшая работа: оценка на протоколе dedup, несколько seed и включение дообученных LLM в ансамбль.

Список литературы

[Conneau et al., 2020] Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of ACL*, pages 8440–8451.

[Dettmers et al., 2023] Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*.

[Devlin et al., 2019] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186.

[Dietterich, 2000] Dietterich, T. G. (2000). Ensemble methods in machine learning. *Multiple Classifier Systems*, pages 1–15.

[Elangovan et al., 2021] Elangovan, A., He, J., and Verspoor, K. (2021). Memorization vs. generalization: Quantifying data leakage in NLP performance evaluation. In *Proceedings of EACL*, pages 1325–1335.

[Golubev and Loukachevitch, 2021] Golubev, A. and Loukachevitch, N. (2021). Transfer learning for improving results on Russian sentiment datasets. *arXiv preprint arXiv:2107.02499*.

[Hu et al., 2022] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., and Chen, W. (2022). LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*.

[Kim, 2014] Kim, Y. (2014). Convolutional neural networks for sentence classification. In *Proceedings of EMNLP*, pages 1746–1751.

[Kotelnikov, 2021] Kotelnikov, E. (2021). Current landscape of the Russian sentiment corpora. *arXiv preprint arXiv:2106.14434*.

[Kuratov and Arkhipov, 2019] Kuratov, Y. and Arkhipov, M. (2019). Adaptation of deep bidirectional multilingual transformers for Russian language. *arXiv preprint arXiv:1905.07213*.

[Li et al., 2023] Li, Z., Li, X., Liu, Y., Xie, H., Li, J., Wang, F.-l., Li, Q., and Zhong, X. (2023). Label supervised LLaMA finetuning. *arXiv preprint arXiv:2310.01208*.

[Loukachevitch and Rubtsova, 2016] Loukachevitch, N. and Rubtsova, Y. (2016). SentiRuEval-2016: Overcoming time gap and data sparsity in tweet sentiment analysis. In *Computational Linguistics and Intellectual Technologies: Proceedings of the International Conference "Dialogue"*.

[Rogers et al., 2018] Rogers, A., Romanov, A., Rumshisky, A., Volkova, S., Gronas, M., and Gribov, A. (2018). RuSentiment: An enriched sentiment analysis dataset for social media in Russian. In *Proceedings of the 27th International Conference on Computational Linguistics*, pages 755–763.

[Smetanin, 2022a] Smetanin, S. (2022a). Evaluation of pre-trained transformers for sentiment analysis of texts in Russian. `https://github.com/sismetanin/sentiment-analysis-in-russian`.

[Smetanin, 2022b] Smetanin, S. (2022b). RuSentiTweet: a sentiment analysis dataset of general domain tweets in Russian. *PeerJ Computer Science*, 8:e1039.

[Smetanin and Komarov, 2019] Smetanin, S. and Komarov, M. (2019). Sentiment analysis of product reviews in Russian using convolutional neural networks. In *2019 IEEE 21st Conference on Business Informatics (CBI)*, volume 1, pages 482–486.

[Smetanin and Komarov, 2021] Smetanin, S. and Komarov, M. (2021). Deep transfer learning baselines for sentiment analysis in Russian. *Information Processing & Management*, 58(3):102484.

[Snegirev et al., 2025] Snegirev, A., Tikhonova, M., Maksimova, A., Fenogenova, A., and Abramov, A. (2025). The Russian-focused embedders' exploration: ruMTEB benchmark and Russian embedding model design. In *Proceedings of NAACL*.

[Wang et al., 2024] Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., and Wei, F. (2024). Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.

[Warner et al., 2024] Warner, B., Chaffin, A., Clavié, B., Weller, O., Hallström, O., Taghadouini, S., Gallagher, A., Biswas, R., Ladhak, F., Aarsen, T., et al. (2024). Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference. *arXiv preprint arXiv:2412.13663*.

[Zhang et al., 2024] Zhang, W., Deng, Y., Liu, B., Pan, S. J., and Bing, L. (2024). Sentiment analysis in the era of large language models: A reality check. In *Findings of NAACL*, pages 3881–3906.

[Zmitrovich et al., 2023] Zmitrovich, D., Abramov, A., Kalmykov, A., Tikhonova, M., Taktasheva, E., Astafurov, D., Baushenko, M., Snegirev, A., Kadulin, V., Markov, S., Shavrina, T., Mikhailov, V., and Fenogenova, A. (2023). A family of pretrained transformer language models for Russian. *arXiv preprint arXiv:2309.10931*.